機械学習を使った組み合わせ最適化
ニューラル組み合わせ最適化の紹介

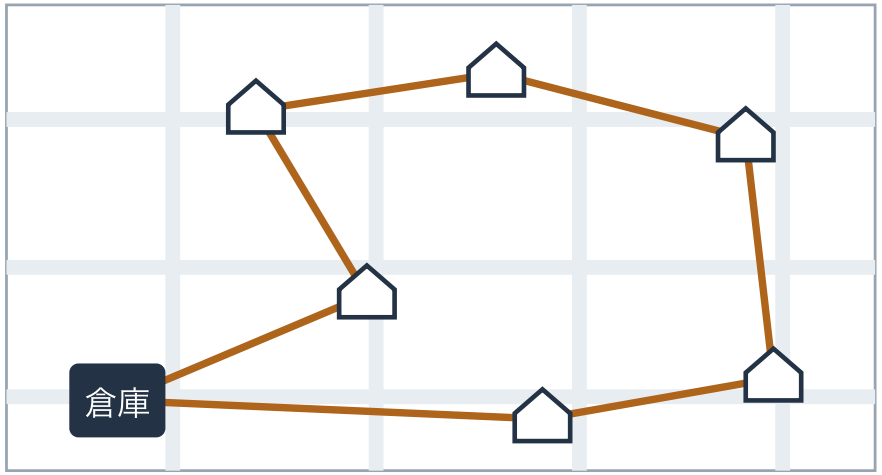
研究背景

01

研究背景

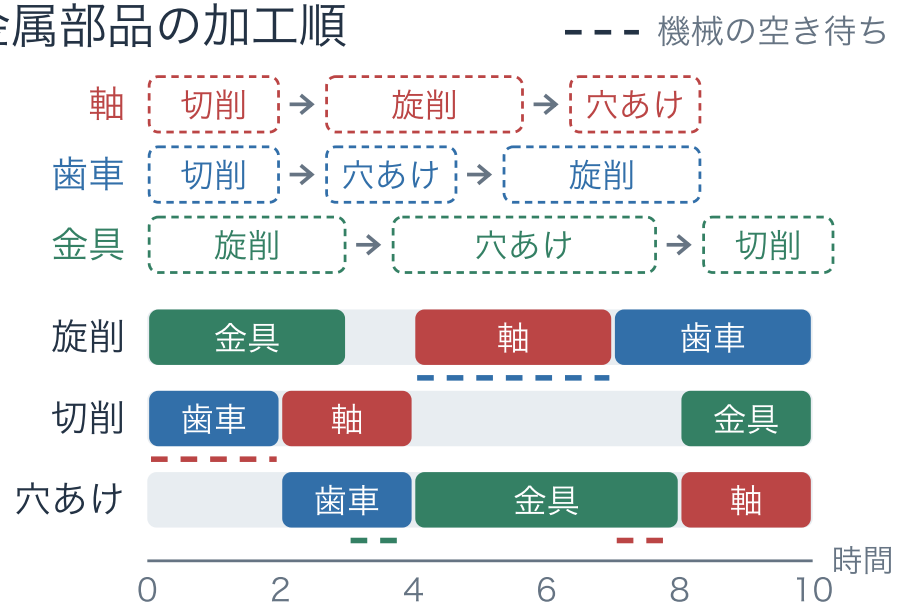
配送の順番や作業の順番など、社会には組合せを考えて決める問題が多くある。

配送経路



決めるもの：訪問する順番
制約：全地点を1回ずつ訪問
目的：総移動距離の最小化

金属部品の加工順



決めるもの：各設備で加工する品目の順番
制約：加工の順序、設備は同時に1品目
目的：全品目の完了時刻を早める

制約を満たす組合せから、目的関数が最もよいものを選ぶ問題を**組合せ最適化**と呼ぶ。[1, 2]

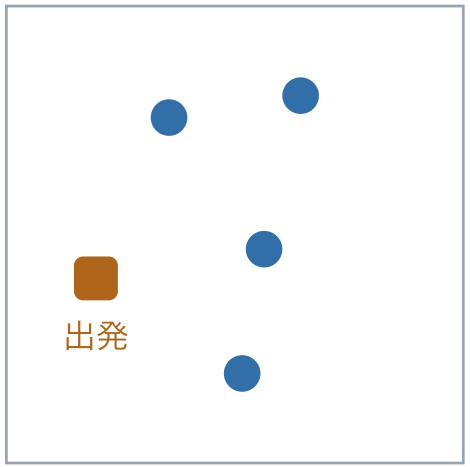
[1] G. Dantzig, R. Fulkerson, S. Johnson. Solution of a Large-Scale Traveling-Salesman Problem . Journal of the Operations Research Society of America . 1954.
[2] Google. The Job Shop Problem .

問題の例：巡回セールスマン問題

全都市を1回ずつ訪問して出発点へ戻る経路を、なるべく短くする問題。

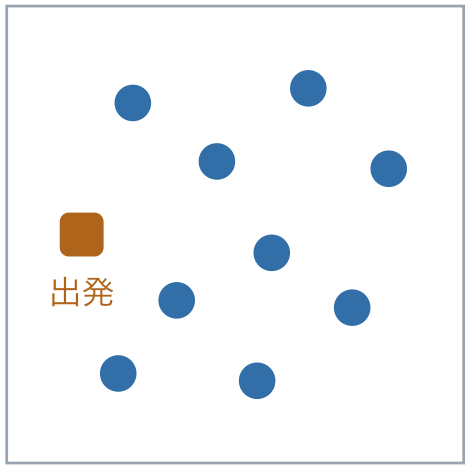
都市がN個のとき経路の順列は(N−1)!通りあり、都市が増えるほど膨大になる。

都市 5個



(5−1)! = 24 通り

都市 10個



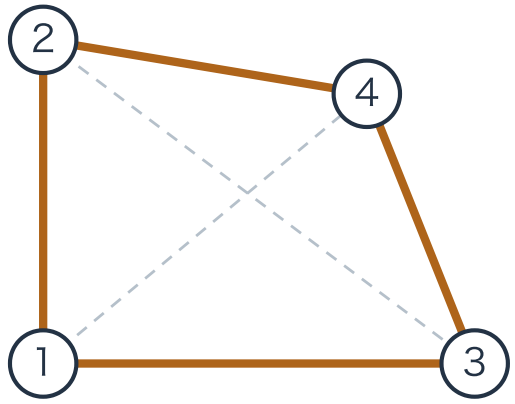
(10−1)! = 362,880 通り

単純に列挙すると候補は階乗のペースで増え、NP困難※な問題として知られる。

※ NP困難：NPに属するどの問題も多項式時間で帰着できる問題。多項式時間で解く方法は知られていない。

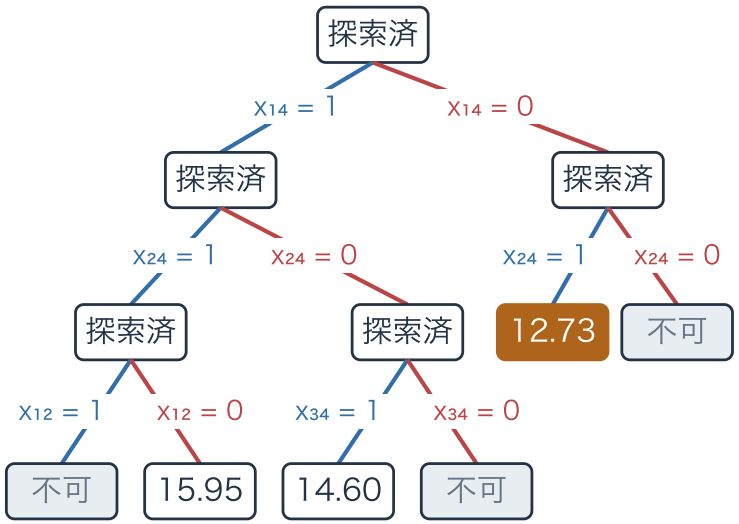
解き方1：数理最適化ソルバー

問題を数式（変数・制約・目的関数）で表し、分枝限定法などで最適解を探す。代表的なソルバーにGurobi、CPLEXがある。[1, 3]



1 → 2 → 4 → 3 → 1

最短経路長 12.73



現在の最良値 12.73

利点

- 探索が完了すれば、許容誤差の範囲で最適性を証明できる
- 制約を式で追加しやすい

欠点

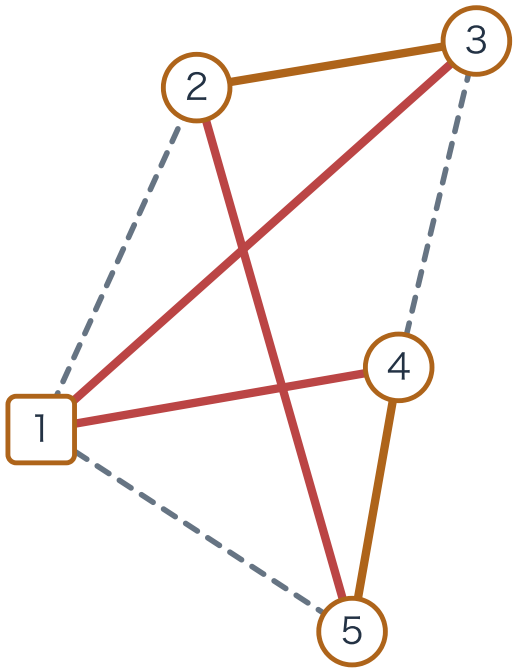
- 問題によっては探索に長い計算時間がかかる
- 問題ごとに定式化の工夫が必要

[1] G. Dantzig, R. Fulkerson, S. Johnson. Solution of a Large-Scale Traveling-Salesman Problem . Journal of the Operations Research Society of America . 1954.
[3] Gurobi Optimization. Objectives: Optimizer Reference Manual .

解き方2：ヒューリスティクス

問題の性質に合わせた手順で、1つの解を素早く作る。

例えば最近傍法では、今いる都市から最も近い未訪問の都市へ順に進む。[4]



訪問順

1 → 4 → 5 → 2 → 3 → 1

最近傍法 2.66

最適 2.10

最適経路と異なる辺

利点

- 計算が速く、大規模でも解を作れる
- 手順が単純で分かりやすい

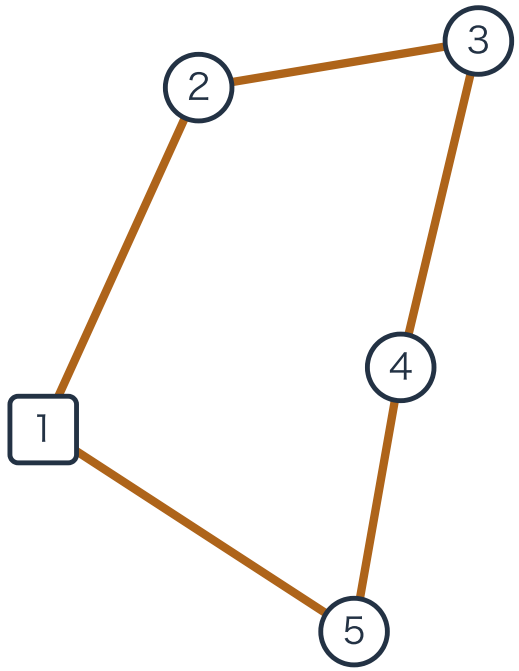
欠点

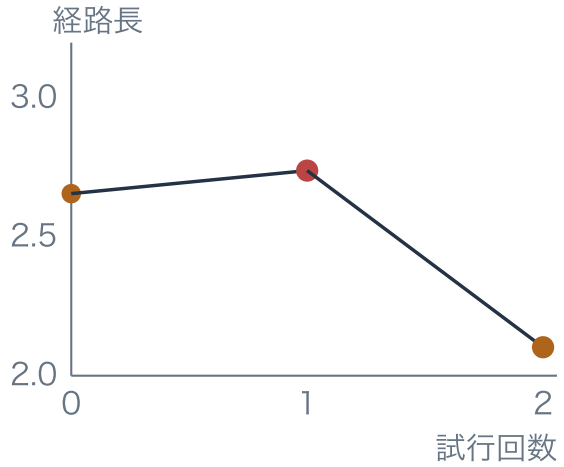
- 解の良さの保証がない
- 良いやり方を人が考える必要がある

[4] S. Lin, B. W. Kernighan. An Effective Heuristic Algorithm for the Traveling-Salesman Problem . Operations Research . 1973.

解き方3：メタヒューリスティクス

解を少しずつ変えて良くしていく探索の枠組み。悪くなる変更もある程度受け入れることで、局所的に良い解から抜け出す。例に焼きなまし法、遺伝的アルゴリズムがある。





短くなる候補を採用

2.74 → 2.10（−23.2%）

利点

- 多くの問題に使え、良い解が得られやすい
- 時間をかけるほど改善できる

欠点

- 問題ごとに変更の仕方（近傍）を設計する必要がある
- 問題を解くたびに一から探索する

組合せ最適化の解き方

解き方	例	速さ	解の良さ
数理最適化ソルバー	Gurobi、CPLEX	△	◎
ヒューリスティクス	最近傍法、貪欲法	◎	△
メタヒューリスティクス	焼きなまし法、遺伝的アルゴリズム	○	○
NCO（学習ベース）	Attention Model [5]	◎	○

これらと異なる解き方として、学習ベースの**NCO**（Neural Combinatorial Optimization）がある。

[5] W. Kool, H. van Hoof, M. Welling. Attention, Learn to Solve Routing Problems! International Conference on Learning Representations (ICLR 2019) . 2019.

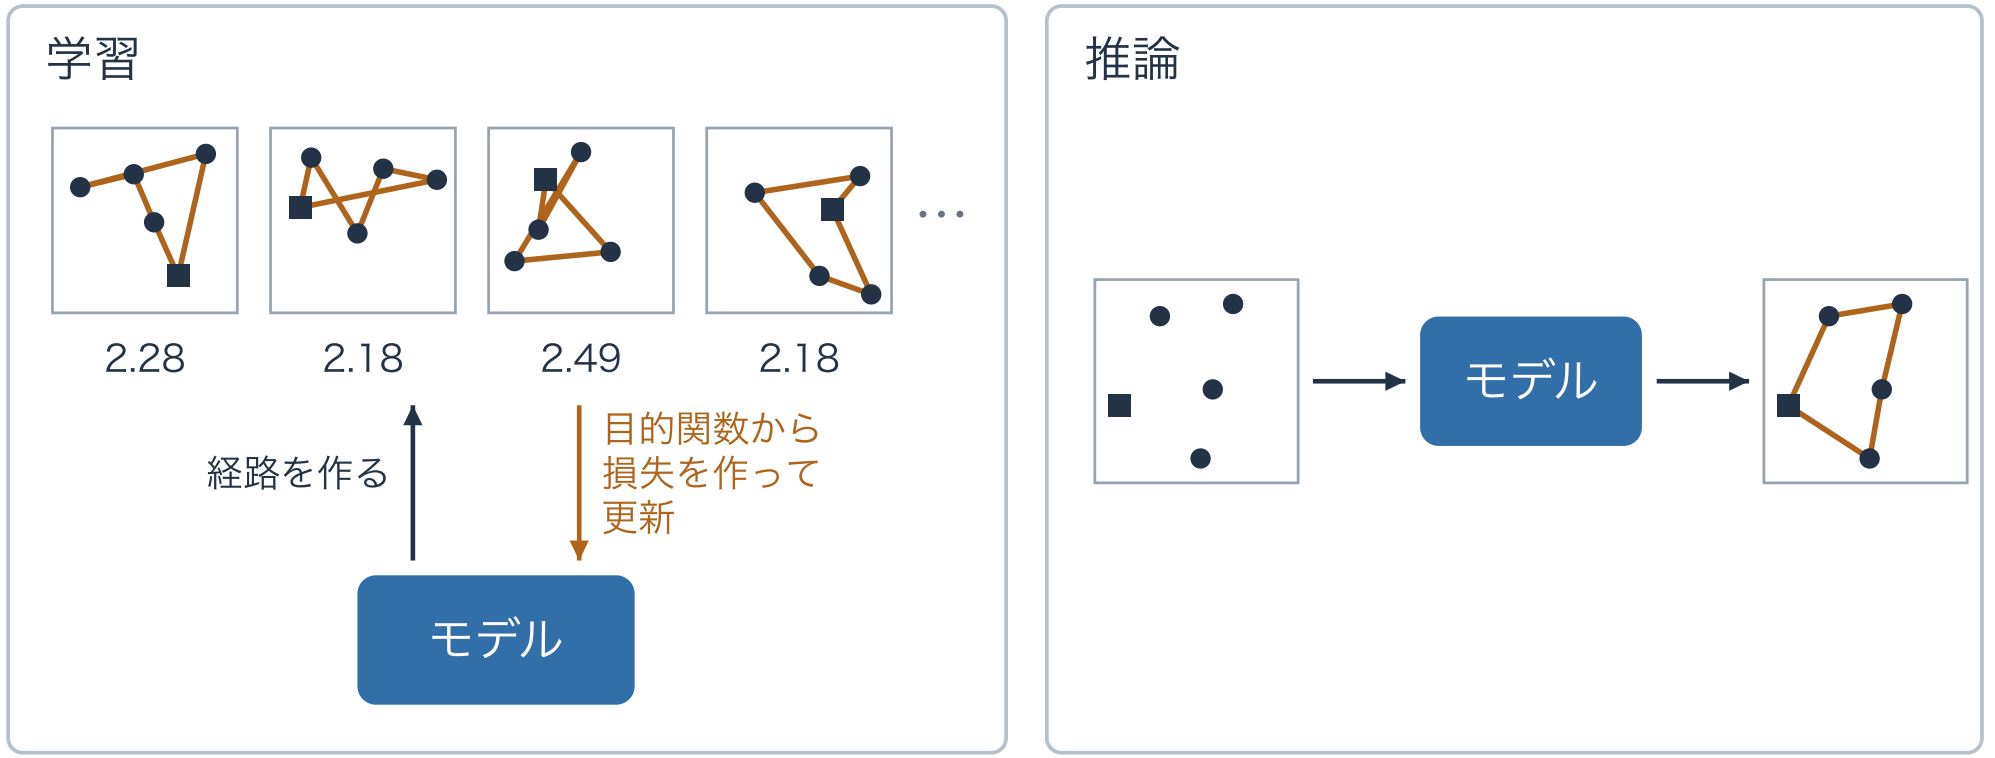
ニューラル組み合わせ最適化

02

NCO：解き方を学習する

同じ種類の問題を大量に解かせて、解の作り方をモデルに学習させる。

学習済みのモデルは、新しい問題に対して探索をやり直さずに解を構成する。



NCOのメリット

学習した規則を、別の問題例にも利用できる。[5, 6]

- 学習済みモデルで短時間に候補解を作れる
- 複数の候補を作り、その中からよい解を選べる
- **質のよい初期解**として、局所探索や他の解法と組み合わせる使い方も考えられる

問題を解くたびの探索に加えて、事前の学習に計算を使う。

[5] W. Kool, H. van Hoof, M. Welling. Attention, Learn to Solve Routing Problems! International Conference on Learning Representations (ICLR 2019) . 2019.

[6] Y.-D. Kwon ほか. POMO : Policy Optimization with Multiple Optima for Reinforcement Learning . Advances in Neural Information Processing Systems (NeurIPS 2020) . 2020.

NCOのデメリットと使いどころ

- **学習が大変**：大量の問題例・計算資源・学習設定の調整が必要
- 規模や分布が変わると、解の質が落ちることがある
- 最適性の保証はなく、制約を守る仕組みも設計する必要がある [5, 7]

日々似た問題を繰り返し解く場面で使えると考えている。

[5] W. Kool, H. van Hoof, M. Welling. Attention, Learn to Solve Routing Problems! International Conference on Learning Representations (ICLR 2019) . 2019.

[7] Z. Liao ほか. BOPO : Neural Combinatorial Optimization via Best-anchored and Objective-guided Preference Optimization . Proceedings of the 42nd International Conference on Machine Learning (ICML 2025) . 2025.

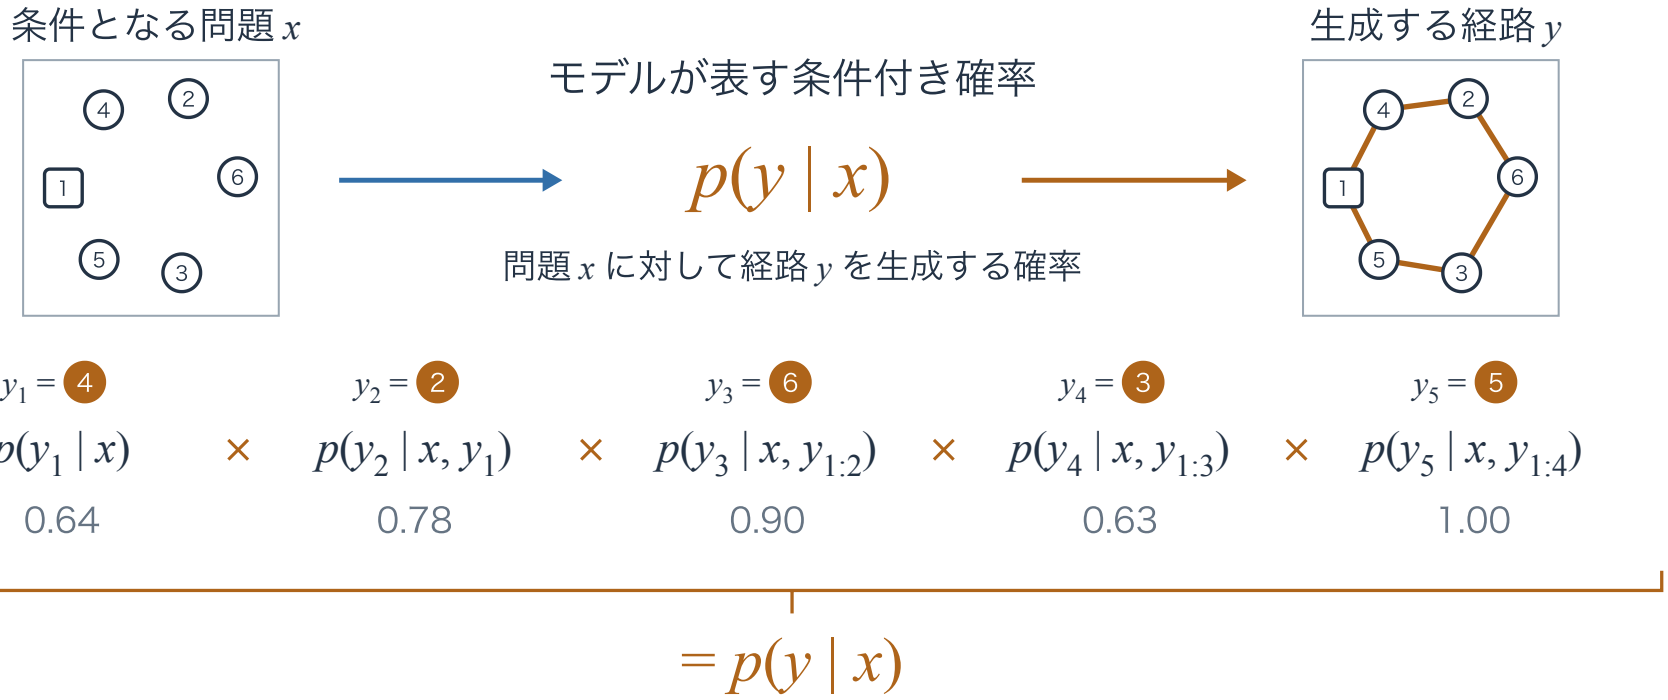
先行研究

03

Attention Model：概要

構成型NCOの代表的なモデルであるAttention Model [5] を説明する。

問題インスタンス x から、行動 y_t を1つずつ選んで解 y を構成する。

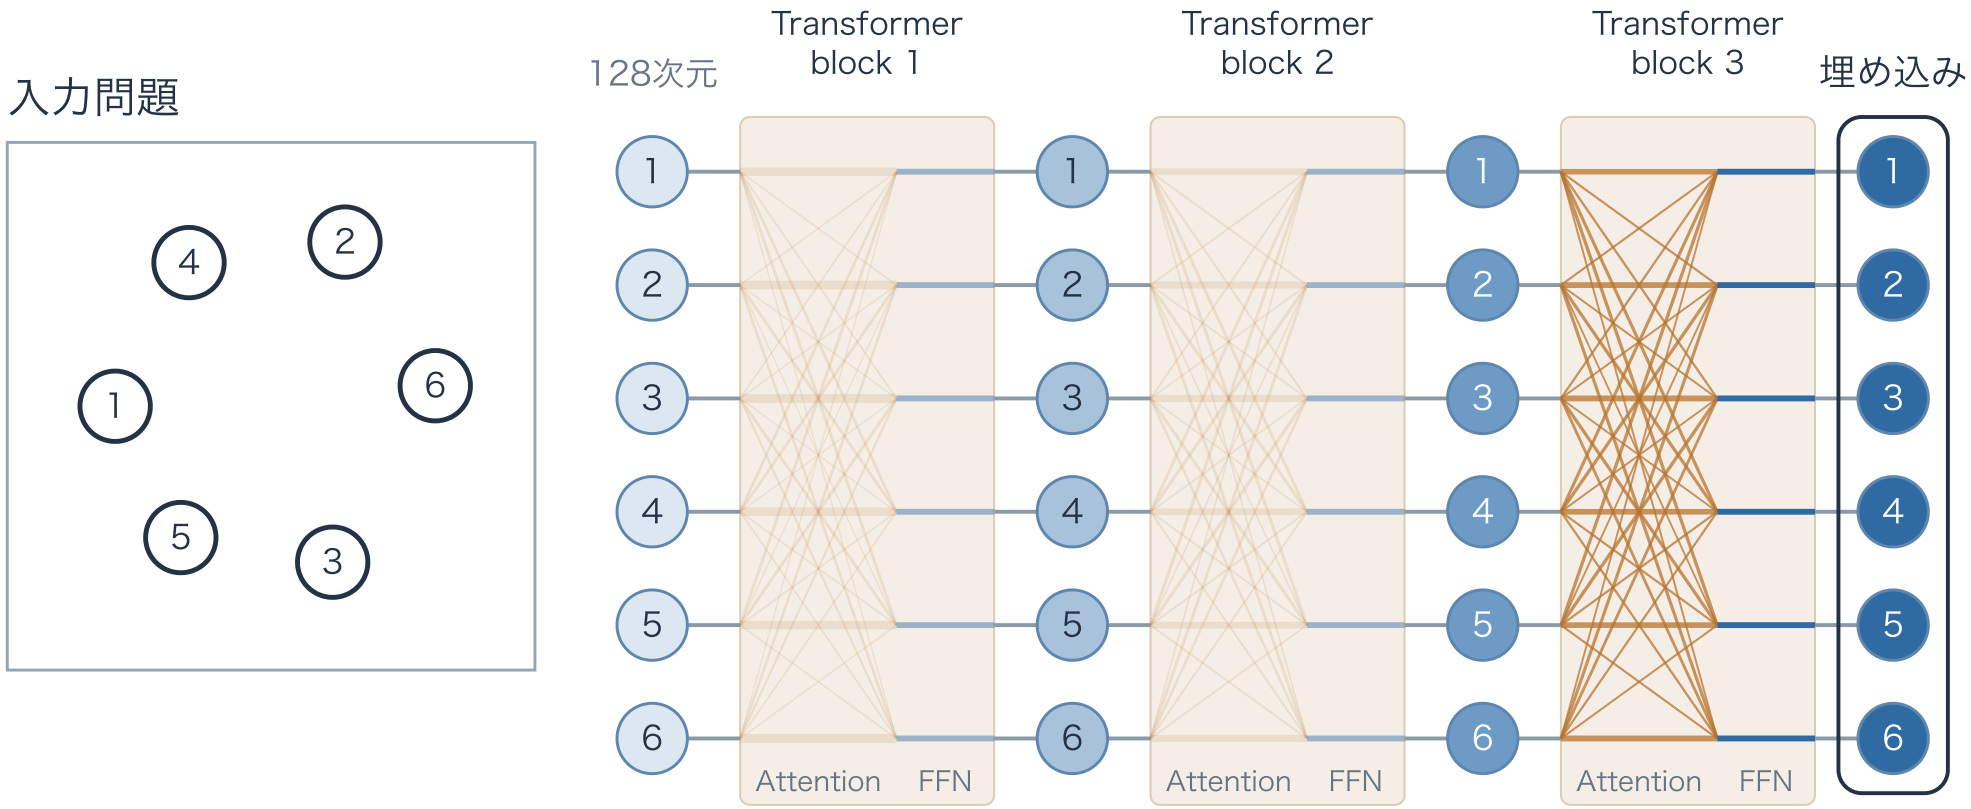


[5] W. Kool, H. van Hoof, M. Welling. Attention, Learn to Solve Routing Problems! International Conference on Learning Representations (ICLR 2019) . 2019.

Attention Model：エンコーダー

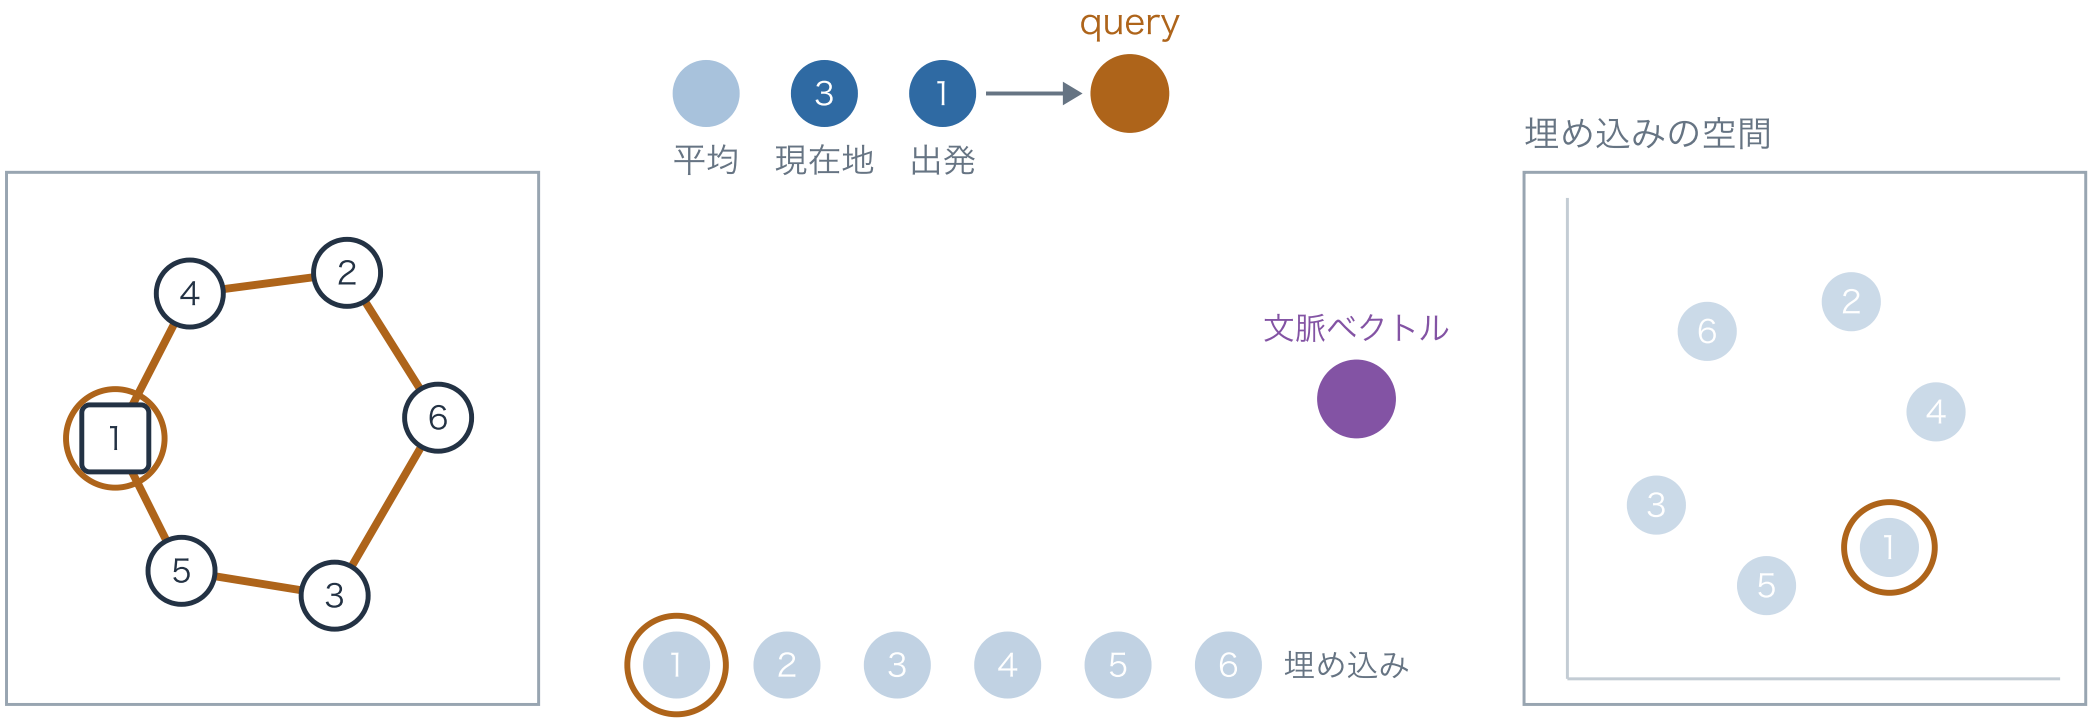
Attention Modelはエンコーダーとデコーダーの構成。

エンコーダーでは各都市を1つのトークンとし、Transformer3層で埋め込みを作る。



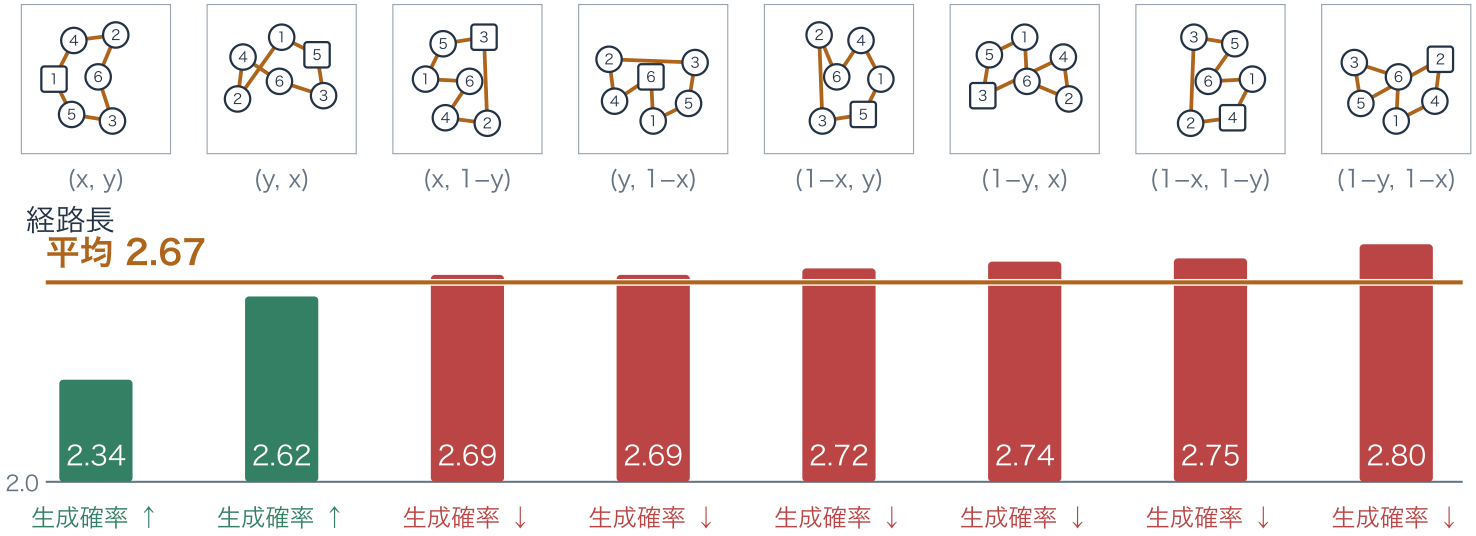
Attention Model：デコーダー

現在の状態と埋め込みから文脈ベクトルを作り、埋め込みとの内積で次の都市を選ぶ。



学習の仕方

TSPは、座標を回転・反転しても、出発点や巡回方向を変えても同じ最適解になる。POMOはこの対称性を利用して複数の経路を作る [6]。



学習時は複数経路の平均経路長を基準に更新する。 推論時は出発点を変えて複数の経路を作り、最も良かったものを採用する。回転・反転による8通りの入力拡張も用いる。

[6] Y.-D. Kwon ほか. POMO : Policy Optimization with Multiple Optima for Reinforcement Learning . Advances in Neural Information Processing Systems (NeurIPS 2020) . 2020.

BOPO：候補解の優劣から学習する

目的関数の値を使い、よい候補が選ばれやすいよう学習する。[7]

- 同じ問題に対して、複数の候補解を生成する
- 最良の候補を基準に、他の候補との選好ペアを作る
- 目的関数値の差を、学習時の重み付けに反映する

Attention Modelのようなモデル構造と、学習方法は区別して考える。

[7] Z. Liao ほか. BOPO : Neural Combinatorial Optimization via Best-anchored and Objective-guided Preference Optimization . Proceedings of the 42nd International Conference on Machine Learning (ICML 2025) . 2025.

実験結果

04

先行研究の実験結果：TSP100

一様分布から生成した100都市の問題、**1,000問**の結果。[7]

手法	平均経路長	ギャップ	合計求解時間
Concorde	7.75	0.00%	1時間
LKH3	7.75	0.00%	25分
POMO（入力拡張あり）	7.77	0.14%	18.1秒
BOPO（入力拡張あり）	7.75	0.04%	18.1秒

BOPO論文 Table 2。時間は学習を除く1,000問の合計。NCOは8通りの入力拡張を使用。論文の実験環境：TITAN Xp GPU・Xeon E5-2680 CPU。手法間で並列化条件も異なる。

[7] Z. Liao ほか. BOPO : Neural Combinatorial Optimization via Best-anchored and Objective-guided Preference Optimization . Proceedings of the 42nd International Conference on Machine Learning (ICML 2025) . 2025.

結果の読み方とまとめ

短時間に良い候補を作る手段として、NCOには可能性がある。[7]

- 同じベンチマークで、POMOからBOPOへギャップが小さくなった
- 表の経路長は丸めた値。7.75でも最適解と一致するとは限らない
- 他の規模・分布・制約でも同じ性能になるとは限らない

学習コストと求解頻度を合わせて、既存の解法との使い分けを考える。

[7] Z. Liao ほか. BOPO : Neural Combinatorial Optimization via Best-anchored and Objective-guided Preference Optimization . Proceedings of the 42nd International Conference on Machine Learning (ICML 2025) . 2025.

参考文献

[1] G. Dantzig, R. Fulkerson, S. Johnson. Solution of a Large-Scale Traveling-Salesman Problem. *Journal of the Operations Research Society of America*. 1954.

[2] Google. The Job Shop Problem.

[3] Gurobi Optimization. Objectives: Optimizer Reference Manual.

[4] S. Lin, B. W. Kernighan. An Effective Heuristic Algorithm for the Traveling-Salesman Problem. *Operations Research*. 1973.

[5] W. Kool, H. van Hoof, M. Welling. Attention, Learn to Solve Routing Problems! *International Conference on Learning Representations (ICLR 2019)*. 2019.

参考文献（2）

[6] Y.-D. Kwon ほか. POMO: Policy Optimization with Multiple Optima for Reinforcement Learning. *Advances in Neural Information Processing Systems (NeurIPS 2020)*. 2020.

[7] Z. Liao ほか. BOPO: Neural Combinatorial Optimization via Best-anchored and Objective-guided Preference Optimization. *Proceedings of the 42nd International Conference on Machine Learning (ICML 2025)*. 2025.